

Conv-41: Segment 口径下 “召回了但没有保留证据” 分析报告

阅读标注

- **绿色**: 客观结果/统计
- **橙色**: 机制因果 (代码行为)
- **红色**: 直接问题与风险
- **蓝色**: 改进建议

本次变更 (关键)

- 已将 `workspace_execute_recall` 的语义改为 **Segment 粒度**:
- 不再以 Episode 命中作为 workspace 召回命中标准;
- 改为 `dialogue_id:episode_id:segment_id` 映射到 `Dk:x` 后再判定命中。
- 变更位置: `scripts/run_locomo/run_eval_locomo.py`

重算结果 (conv-41)

- `overall_recall = 0.885197` (final evidence 口径, 不变)
- `overall_workspace_execute_recall = 0.918...` (由原先 episode 宽松口径下降)
- 满足条件 `memory_agent_recall == 0 && memory_agent_workspace_execute_recall > 0` 的题目:
- 由 7 题降到 6 题: `Q3, Q8, Q31, Q52, Q64, Q82`
- `Q41` 被剔除 (说明它此前的 “命中” 主要是 episode 粗粒度带来的乐观估计)

筛选条件与判定标准

- 条件 A: `memory_agent_workspace_execute_recall > 0` (Segment 口径下确实召回过支持 gold 的 segment)
- 条件 B: `memory_agent_recall == 0` (最终 evidence 没命中 gold)
- 解释: 这组题是 “检索阶段命中过, 最终保留阶段没留下”。

逐题分析 (Segment 口径)

Q3 — What type of volunteering have John and Maria both done?

- **结果:** `workspace_execute_recall=0.5, recall=0.0`
- **gold:** `D3:5, D2:1`
- **命中的 segment:** `dlg_locomol0_conv-41_3:ep_001:seg_001`
- **生命周期:**
 - `seen_in_execute_rounds = [3]`
 - `in_useful_rounds = []`
 - `in_kept_after_judge_rounds = []`
- **因果:** 该命中 segment 在执行池出现过, 但从未被 judge 选为 useful, 随后在 `prune_except(useful ∪ new)` 逻辑下未进入保留集。
- **问题:** 命中过但未晋升为可保留证据, 属于“执行命中 -> judge 筛选断链”。

Q8 — What might John's financial status be?

- **结果:** `workspace_execute_recall=1.0, recall=0.0`
- **gold:** `D5:5`
- **命中的 segment:** `dlg_locomol0_conv-41_5:ep_001:seg_001`
- **生命周期:**
 - `seen_in_execute_rounds = [1, 2, 3]`
 - `in_useful_rounds = [1, 2]`
 - `in_kept_after_judge_rounds = [1, 2]`
- **最终轮保留:** 否
- **因果:** 前两轮曾被判 useful 并保留, 但第三轮 query 漂移后 useful 集合发生替换, 旧证据被覆盖式裁剪掉。
- **问题:** 典型“先保住、后丢失”。

Q31 — When did John get his dog Max?

- **结果:** `workspace_execute_recall=1.0, recall=0.0`
- **gold:** `D17:1`
- **命中的 segment:** `dlg_locomol0_conv-41_17:ep_001:seg_001`
- **生命周期:**
 - `seen_in_execute_rounds = [1, 2]`
 - `in_useful_rounds = []`
 - `in_kept_after_judge_rounds = [1]`
- **最终轮保留:** 否

- **因果**: judge 两轮 `useful_ids` 均为空（结构化产出不稳），系统退化到“按 new 替换”，导致第一轮保住的命中证据在第二轮被覆盖。
- **问题**: judge 空输出触发破坏性更新。

Q52 — Who have written notes of gratitude to Maria?

- **结果**: `workspace_execute_recall=1.0`, `recall=0.0`
- **gold**: `D27:8`, `D21:19`
- 命中的 segment:
- `dlg_locomol0_conv-41_21:ep_001:seg_004`
- `dlg_locomol0_conv-41_27:ep_001:seg_002`
- 生命周期:
- `seen_in_execute_rounds = [1,2]`
- `in_useful_rounds = []`
- `in_kept_after_judge_rounds = [1]`
- 最终轮保留: 否
- **因果**: 和 Q31 同型, judge 输出为空后触发覆盖式替换, 第二轮把第一轮命中证据清掉。
- **问题**: 保留链路对 judge 异常过敏。

Q64 — What job might Maria pursue in the future?

- **结果**: `workspace_execute_recall=0.75`, `recall=0.0`
- **gold**: `D32:14`, `D5:8`, `D11:10`, `D27:4`
- 命中的 segment:
- `dlg_locomol0_conv-41_11:ep_001:seg_003`
- `dlg_locomol0_conv-41_27:ep_001:seg_002`
- `dlg_locomol0_conv-41_5:ep_001:seg_002`
- 生命周期:
- `seen_in_execute_rounds = [2,3]`
- `in_useful_rounds = []`
- `in_kept_after_judge_rounds = []`
- 最终轮保留: 否
- **因果**: 命中过的 segment 没有被 judge 认定 useful, 始终无法进入保留集。
- **问题**: 执行命中与 judge 选择目标不一致。

Q82 — What did John receive a certificate for?

- **结果**: `workspace_execute_recall=1.0`, `recall=0.0`

- gold: D9:2
 - 命中的 segment: dlg_locomo10_conv-4l_9:ep_001:seg_001
 - 生命周期:
 - `seen_in_execute_rounds = [1,2]`
 - `in_useful_rounds = []`
 - `in_kept_after_judge_rounds = [1]`
 - 最终轮保留: 否
 - **因果**: 第一轮短暂保留, 第二轮在 judge 空 useful 输出下被替换掉。
 - **问题**: 与 Q31/Q52 同模式。
-

机制结论 (Segment 口径下仍成立)

1. 硬覆盖裁剪是主因

`prune_except(useful ∪ new)` 使历史正确证据没有“存活保护”。

2. judge 空 useful 输出是高危触发器

一旦 useful 为空, 保留策略会退化成“只看新证据”, 容易把已命中的旧证据清掉。

3. Segment 口径验证了此前判断

误报减少 (Q41退出候选), 但“召回命中 -> 最终不保留”的真实问题依然明显存在。

建议 (本轮)

1. P0: Judge 异常保护

`useful_ids` 为空或解析失败时, 禁止 destructive prune, 冻结上一轮 kept。

2. P0: 命中锚点保护

命中过 gold-like 证据后, 后续轮次默认保护, 不因 query 改写自动丢弃。

3. P1: 持续保留 Segment 指标

`workspace_execute_recall` 固定采用 segment 口径; episode 仅作辅助统计, 不作主指标。

4. P1: 增加生命周期监控

记录 `seen_in_execute` / `in_useful` / `in_kept_after_judge` / `in_final`, 定位具体丢失阶段。